Machine Learning- Final Report

多模態病理嗓音分類

數據所 RE6124035 黃亮臻

Background

近年,隨著高壓的生活環境,各式各樣的文明病引起醫學界的注意,其中嗓音疾病常見於職業上需要大量用聲族群,如老師、業務、講師、零售攤販等,由於聲帶位處於喉部深處,喉部嗓音疾病檢測相當不易,需專業醫師操作特定儀器方能對病患進行診斷及治療,再加上現代人工作繁忙,不時有延誤就醫之情形。

在近年 COVID-19 盛行期間,張口進行內視鏡檢查恐有飛沫傳播之風險。若能將人工智慧應用於非接觸式,透過嗓音訊號(動態聲音)結合病史紀錄(靜態文字)偵測喉部病徵並分類,有機會早期發現,早期治療,將會是所有嗓音患者之一大福音。

Data Description

- 資料來源:
 - 亞東醫院 耳鼻喉科嗓音資料庫
 - 教育部人工智慧競賽與標註資料蒐集計畫
- 資料格式: 病史紀錄(csv) + 嗓音訊號(wav)
- Train: 1000 位病人, Test: 500 位病人
- 病史紀錄: 26 個變數
- 嗓音訊號: 1~3秒鐘的 "啊"

病史紀錄

- Y: 嗓音診斷分類
- 1. 嗓音誤用
- 2. 聲帶閉合不全
- 3. 聲帶麻痺
- 4. 聲帶腫瘤
- 5. 聲帶正常



變數	Scale	說明
性別	1/2	男性/女性
年齡	numbers	
音域變窄	0/1	無/有
說話音量變小	0/1	無/有
說話久了容易累	0/1	無/有
喉嚨常覺得乾	0/1	無/有
喉嚨有異物感	0/1	無/有
胸口有灼熱感	0/1	無/有
吞東西容易嗆到	0/1	無/有

病史紀錄

 變數	Scale	 說明
眼睛乾澀	0/1	 無 / 有
鼻涕倒流	0/1	無/有
糖尿病	0/1	無/有
高血壓	0/1	無/有
心臟病	0/1	無/有
頭頸部腫瘤	0/1	無/有
頭部損傷	0/1	無/有
腦中風	0/1	無/有
抽菸	0/1/2/3	從未/已戒菸/有抽菸/ 電子菸

變數	Scale	說明		
PPD	numbers	一天幾包菸		
喝酒	0/1/2	從未喝酒/已戒酒/有喝酒		
喝酒頻率	0/1/2/3	偶爾喝/每周喝/幾乎每天		
症狀如何發生的	1/2/3/4/5	突然/逐漸變差/時好時壞/ 從小開始/其他		
工作環境是否吵雜	1/2/3	否/有一點/很吵		
聲音何時最差	1/2/3/4	早上/下午、晚上 /都一樣/ 不一定		
用聲情形	1/2/3/4	總是需要/經常需要/偶而需 要/不需要		
VHI-10嗓音障礙指標 0 to 40				

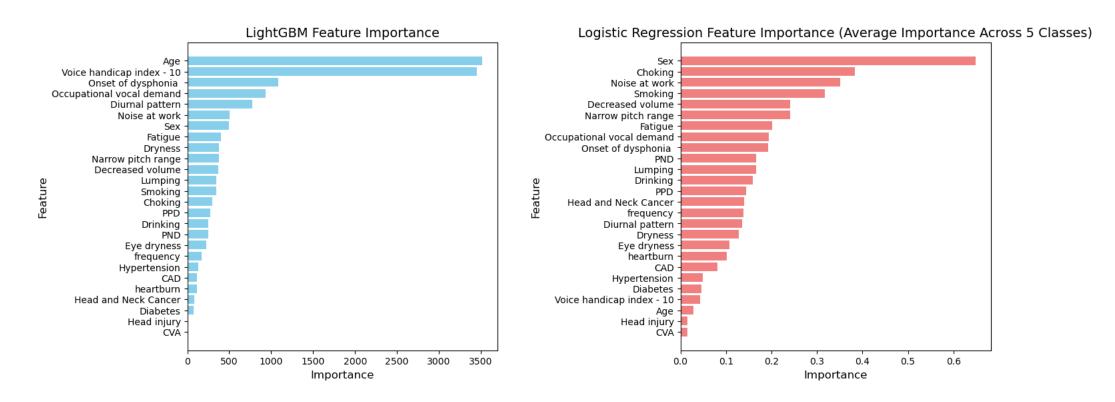
Missing Value

- PPD (一天幾包煙):將從未抽過煙及已戒煙的人補0, 其他取中位數
- VHI-10嗓音障礙指標:使用 KNN Imputer 補值

	Count of Missing Values
ID	0
Sex	0
Age	0
Disease category	0
Narrow pitch range	0
Decreased volume	0
Fatigue	0
Dryness	0
Lumping	0
heartburn	0
Choking	0
Eye dryness	0
PND	0
Smoking	0
PPD	816
Drinking	0
frequency	0
Diurnal pattern	0
Onset of dysphonia	0
Noise at work	0
Occupational vocal demand	0
Diabetes	0
Hypertension	0
CAD	0
Head and Neck Cancer	0
Head injury	0
	0
CVA Voice handicap index - 10	

Feature Extraction

• 病史紀錄:LightGBM (Feature Importance) + Multinominal Logistic (Coef.)



最重要的前15個變數為: 一天幾包菸, 抽菸, 音域變窄, 性別, 鼻涕倒流, 工作環境是否吵雜, 喉嚨常覺得乾, 說話久了容易累, 症狀如何發生的, 喝酒, 吞東西容易嗆到, 聲音何時最差, 說話音量變小, 用聲情形, 喉嚨有異物感

Categorical Variable

Nominal 變數

• 法一: One Hot Encoding: Nominal 變數剛好都是兩類

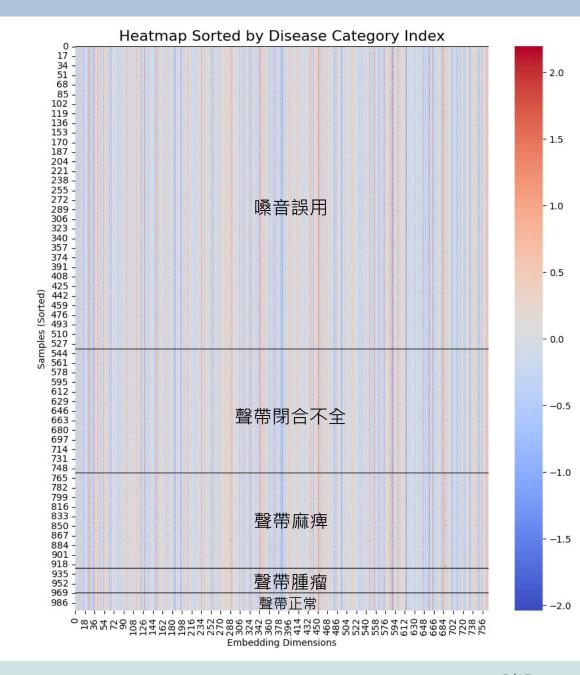
• 法二: Multiple Correspondence Analysis (MCA)

Ordinal 變數:維持原樣

Ex: 抽菸 (1:從未/ 2:已戒菸/ 3:有抽菸/ 4:電子菸), 喝酒 (1:從未喝酒 /2:已戒酒/ 3:有喝酒), 用聲情形 (1:總是需要/2:經常需要/3:偶而需要/4:不需要)

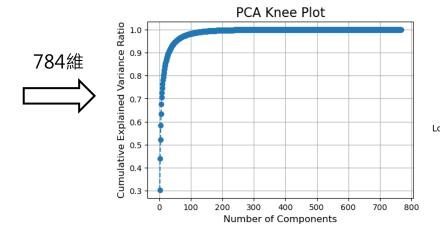
嗓音訊號

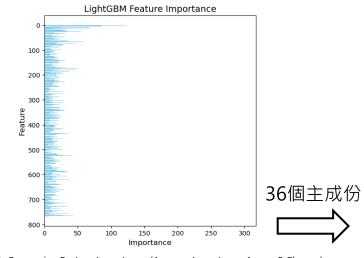
- 將音檔長度固定為2秒
 - 不足 2 秒:提取音檔的中間部分,複製並插入到音檔的中間,補齊 2 秒
 - 超過2秒:刪除中間段,確保音檔總長度縮減 到2秒
- Fine-tune Wav2Vec2 , 得到 784 維 Embedding

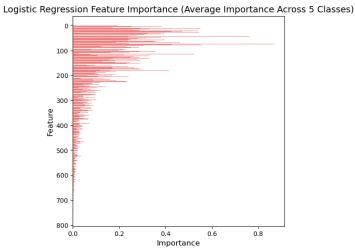


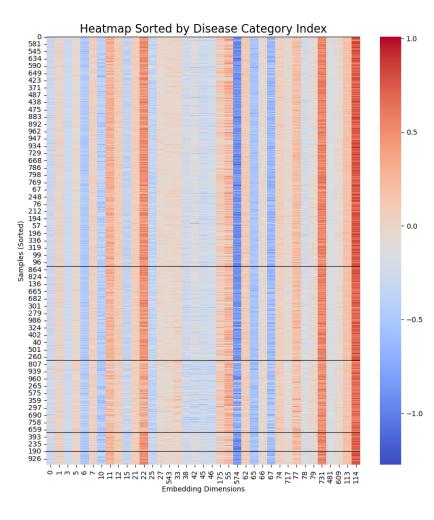
Feature Extraction

使用 PCA 將嗓音訊號濃縮特徵,並將主成份再一次進行特徵選取









實驗結果

Method	Model	Accuracy	Recall (weighted)	Precision (weighted)	F1-Score (weighted)
病史資料(Feat. Sel.)	Logistic	0.642	0.642	0.575	0.602
	SVM	0.694	0.694	0.631	0.654
	XGB	0.644	0.644	0.610	0.623
	LGBM	0.672	0.672	0.639	0.648
病史資料(Feat. Sel.) + 嗓音資料 PCA (Top)	Logistic	0.728	0.728	0.688	0.701
	SVM	0.712	0.712	0.652	0.673
	XGB	0.698	0.698	0.658	0.669
	LGBM	0.700	0.700	0.654	0.666
病史資料(Feat. Sel.) + 嗓音資料 PCA (Feat. Sel.)	Logistic	0.718	0.718	0.658	0.683
	SVM	0.714	0.714	0.657	0.677
	XGB	0.718	0.718	0.661	0.686
	LGBM	0.714	0.714	0.654	0.679
病史資料(Feature Selection) + 嗓音資料 PCA (Feat. Sel.) + MCA	Logistic	0.738	0.738	0.675	0.701
	SVM	0.722	0.722	0.661	0.681
	XGB	0.724	0.724	0.663	0.689
	LGBM	0.715	0.715	0.655	0.655

Conclusion

- 透過將聲音特徵與病史資料結合,提升了模型的分類準確性。
- 病理嗓音的微小特徵容易被高維數據中的不相關訊息掩蓋。透過 PCA 的特徵濃縮與後續 特徵選取,進一步挖掘真正有用的特徵。

